

Sprint I

Análisis y visualización de la Información

Integrantes:

-Adrian Ruiz Garfias

-Braulio Jimenez Chavez

-Maria Alondra Castillo Galindo

-Jesus Ernesto Vallejo Ayala

-Jose Alberto Bautista Bautista

-Juan Manuel Ramos Reynaga

Profesor: Nayeli Areli Zepeda Padilla

Sección: D04

Introducción

Durante el mes de marzo de 2024 se realizó un análisis exhaustivo de la calidad del aire en la estación Miravalle, con el propósito de transformar los datos horarios en información útil para la comunidad académica y cumplir con los lineamientos de la NOM-172-SEMARNAT-2023. El trabajo partió de la descripción y preparación de los datos, que incluyó la integración de registros horarios y diarios de los contaminantes O_3, CO, PM_{10} y $PM_{2.5}$, así como la bitácora de control de calidad que documenta los valores atípicos y las decisiones tomadas sobre su conservación. La base de datos se estructuró en rejillas completas de 744 horas, con validación de rangos físicos y consistencia entre variables, asegurando que $PM_{2.5}$ no superara a PM_{10} en la misma hora y que los valores imposibles fueran identificados y clasificados.

1. Descripción y Preparación de los Datos

1.1 Contexto y Alcance del Conjunto de Datos

Para la evaluación de la calidad del aire en la estación de monitoreo **Miravalle** (perteneciente a la red del Sistema de Monitoreo Atmosférico de Jalisco, SIMAJ), se delimitó el conjunto de datos al periodo comprendido del **1 al 31 de marzo de 2024** (744 registros horarios).

Tras la auditoría inicial de las variables disponibles en la estación, se determinó enfocar el estudio en cuatro contaminantes criterio con suficiencia de monitoreo:

- **Ozono (O_3)**
- **Monóxido de Carbono (CO)**
- **Material Particulado menor a 10 micrómetros (PM_{10})**
- **Material Particulado menor a 2.5 micrómetros ($PM_{2.5}$)**

El preprocesamiento comprendió un pipeline de limpieza estructurado para resolver problemas de calidad de datos, garantizar la reproducibilidad de los cálculos y cumplir con los criterios de validación de la **NOM-172-SEMARNAT-2023**.

1.2 Auditoría y Tratamiento de Calidad de Datos

A) Valores Faltantes (Completitud)

Se categorizó la ausencia de datos según su magnitud y recurrencia:

- **Ausencia Total (100% de pérdida):**

1. Variables como Dióxido de Azufre (SO_2), Radiación Solar (RS) e Índice UV (UVI) presentaron $8,784$ valores nulos sobre el consolidado anual de $8,784$ horas (100% de inactividad instrumental).
2. Precipitación Pluvial (PP) registró $8,778$ celdas vacías (99.9% de ausencia).
3. *Acción:* Estas variables fueron excluidas del análisis operativo al no contar con la base empírica mínima para el cálculo de indicadores.

- **Ausencia Parcial y Crítica:**
  1. Los óxidos de nitrógeno (NO, NO_2 y NO_x) mostraron pérdidas superiores al 63.8% (entre $5,610$ y $5,671$ horas sin registro).
  2. La Humedad Relativa (RH) presentó $4,600$ registros ausentes (52.3%).
  3. En los contaminantes normados para marzo: $PM_{2.5}$ acumuló un 21.7% de horas faltantes ($1,909$ horas anuales / 194 horas en el mes), O_3 un 9.1% (804 horas anuales / 61 en el mes) y PM_{10} un 8.3% (733 horas anuales / 74 en el mes).
- **Etiología Técnica:** Desconexión o falla electro-óptica de sensores, interrupciones en el suministro de energía eléctrica de la estación, ciclos de calibración programada, mantenimiento preventivo/correctivo y pérdidas de paquetes en la telemetría hacia el servidor central.
- **Efecto Operativo:** Genera asimetrías temporales que comprometen la continuidad de ventanas móviles y causan sesgos en el cálculo de métricas de exposición acumulada.
- **Tratamiento:** Se implementaron criterios estrictos de suficiencia según la NOM-172-SEMARNAT-2023:
  1. *Ventanas horarias cortas:* Para NowCast de PM_{10} y $PM_{2.5}$, se validó la presencia de al menos 2 de las 3 horas más recientes en un horizonte de 12 horas.
  2. *Ventanas móviles de CO:* Se exigió un mínimo del 75% de datos válidos (al menos 6 de 8 horas retrospectivas).
  3. *Balance diario:* Días con menos de 18 horas válidas (<75%) se marcaron como "No cumple", bloqueando el cálculo del indicador diario para evitar imputaciones artificiales en periodos prolongados de falla.

B) Integridad Estructural y Duplicados

- **Diagnóstico:** Se evaluó la clave primaria compuesta por las dimensiones temporales $[DATE, HOUR]$. La estación Miravalle presentó una integridad estructural del 100% para la serie temporal de 2024, sin duplicación de filas ni lecturas redundantes en la misma marca de tiempo.

- **Etiología de Riesgo:** Reintentos automáticos de transmisión (handshake duplicado del datalogger), concatenaciones erróneas en el pipeline de ingesta o fallas en consultas batch de bases de datos relacionales.
- **Efecto Evitado:** La ausencia de registros redundantes previene la sobreponderación artificial de periodos específicos que distorsionan medias móviles y sesgan las distribuciones horarias.
- **Tratamiento:** Se mantuvo una rutina preventiva de deduplicación basada en `subset=['DATE', 'HOUR'], keep='first'` dentro del script de ingesta.

C) Errores de Formato e Inconsistencias Sintácticas

- **Datos Mixtos y Polimorfismo de Tipos:** La columna $PM_{2.5}$ proveniente de la hoja original presentó tipos de datos heterogéneos (`int64`, `float64` y cadenas de texto), provocando que los motores de ingesta la tipificaran de forma genérica como `object`.
- **Redundancia Temporal:** Existencia paralela de la columna `HOUR` (entero de 0 a 23) y la estampa de tiempo `DATE` (`YYYY-MM-DD HH:MM:SS`), introduciendo redundancia sintáctica y riesgo de desfase en indexación.
- **Etiología Técnica:** Exportaciones heterogéneas desde el software de adquisición de datos, presencia de espacios en blanco (`" "`), etiquetas de control como `"No Detectado"` o `"S/D"`, y discrepancias regionales en delimitadores numéricos (comas decimales frente a puntos).
- **Efecto:** Interrupción en la ejecución de funciones vectorizadas, fallo en operaciones matemáticas y bloqueo de rutinas de filtrado cronológico.
- **Tratamiento:** Normalización mediante expresiones regulares para sanear caracteres no numéricos, parsing cronológico unificado con `pd.to_datetime()` y reindexación estricta de la serie horaria continua.

D) Detección y Evaluación Contextual de Valores Atípicos (Outliers)

Mediante el método del Rango Intercuartílico, se identificaron lecturas numéricamente anómalas. No obstante, en el contexto del monitoreo atmosférico metropolitano, se aplicó un criterio de discriminación física para separar fallas instrumentales de contingencias ambientales reales

E) Corrección y Conversión Explícita de Tipos de Datos

- **Diagnóstico:** Detección de cadenas alfanuméricas residuales en columnas analíticas debido a etiquetas de error de telemetría y metadatos de mantenimiento.
- **Efecto:** Imposibilidad de cálculo en las matrices numéricas de NumPy/Pandas y fallos de tipo `TypeError` al invocar métodos estadísticos continuos.
- **Tratamiento Aplicado:** Coerción numérica universal mediante:

```python
df['CO'] = pd.to_numeric(df['CO'], errors='coerce')
df['PM2.5'] = pd.to_numeric(df['PM2.5'], errors='coerce')
df['PM10'] = pd.to_numeric(df['PM10'], errors='coerce')
df['O3'] = pd.to_numeric(df['O3'], errors='coerce')
```

2. Metodología de Transformación y Cálculos Horarios

La fase de transformación de datos horarios se estructuró a partir de los requerimientos técnicos de la **NOM-172-SEMARNAT-2023** para generar los indicadores retrospectivos de exposición inmediata y categorizar el riesgo a la salud en cada hora del periodo.

2.1 Algoritmos y Formulaciones Matemáticas

A) NowCast para Partículas Suspendidas (PM_{10} y $PM_{2.5}$)

El indicador horario de partículas se calculó a partir de una ventana móvil retrospectiva de 12 horas consecutivas. Para garantizar representatividad estadística, el algoritmo exige una condición de suficiencia mínima: deben existir lecturas válidas en **al menos 2 de las 3 horas más recientes** de la ventana.

1. **Determinación del factor de peso (W):** Se calcula la amplitud entre la concentración máxima (c-max) y mínima (c-min) registradas en un lapso de tiempo de 12 horas

$$w_{\text{raw}} = 1 - \left(\frac{C_{\max} - C_{\min}}{C_{\max}} \right) \quad \text{si } C_{\max} > 0 \quad (\text{redondeado a 2 decimales})$$

A fin de evitar una pérdida excesiva de memoria histórica frente a fluctuaciones severas, se aplica la cota inferior normativa:

$$W = \max(w_{\text{raw}}, 0.5)$$

Promedio ponderado temporal (P): Donde i representa la antigüedad del dato ($i = 0$ para la hora actual t, $i = 1$ para $t - 1$, hasta $i = 11$), asignando mayor ponderación a las lecturas más recientes:

$$P = \frac{\sum_{i=0}^{11} (C_i \cdot W^i)}{\sum_{i=0}^{11} W^i}$$

Ajuste y redondeo: El promedio ponderado resultante se somete a los factores de corrección y redondeo a cero decimales:

- Para PM_{10}:
- $NowCast_{PM10} = redondear(redondear(P, 0) \cdot 0.714)$
- Para $PM_{2.5}$:
- $NowCast_{PM2.5} = redondear(redondear(P, 0) \cdot 0.694)$

B) Promedio Móvil de 8 Horas para Monóxido de Carbono (CO_{8h})

A diferencia de las partículas, el impacto toxicológico del monóxido de carbono depende de la exposición sostenida. Se define mediante un promedio aritmético sobre una ventana retrospectiva de 8 horas:

$$\mathrm{CO_{8h}} = \frac{1}{n} \sum_{k=0}^{7} C_{t-k}$$

Criterio de suficiencia horaria: Se requiere un mínimo del \$75\%\$ de completitud en la ventana; es decir, al menos $n \geq 6$ observaciones válidas. Si existen menos de 6 datos, el valor se marca como no disponible (NaN).

2.2 Categorización Horaria según la NOM-172-SEMARNAT-2023

Una vez obtenidos los indicadores horarios base ($NowCast$ para partículas, CO_{8h} para monóxido de carbono y la concentración horaria instantánea para O_3), cada contaminante se clasifica en una de las cinco categorías del Índice AIRE Y SALUD:

```python
# Puntos de corte oficiales NOM-172
    cortes = {
        'PM10':  [0, 45, 70, 132, 213, np.inf], # µg/m³
        'PM2.5': [0, 15, 41, 79, 130, np.inf],  # µg/m³
        'O3':    [0, 0.058, 0.090, 0.135, 0.175, np.inf], # ppm
        'CO':    [0, 5, 9, 12, 16, np.inf]      # ppm
    }

      categorias = ['Buena', 'Aceptable', 'Mala', 'Muy Mala', 'Extremadamente Mala']
```

Categoría	Intervalo CO8h (ppm)	Intervalo O3 (ppm)	Intervalo PM10 (µg/m3)	Intervalo PM2.5 (µg/m3)	Nivel de Riesgo Asociado
Buena	≤ 5.00	≤ 0.058	≤ 45	≤ 15	Bajo
Aceptable	$> 5.00 y \leq 9.00$	$> 0.058\, y \leq 0.090$	$> 45 y \leq 70$	$> 15 y \leq 41$	Moderado
Mala	$> 9.00 y \leq 12.00$	$> 0.090\, y \leq 0.135$	$> 70 y \leq 132$	$> 41 y \leq 79$	Alto
Muy Mala	$> 12.00 y \leq 16.00$	$> 0.135 y \leq 0.175$	$> 132 y \leq 213$	$> 79 y \leq 130$	Muy Alto
Extremadamente Mala	> 16.00	> 0.175	> 213	> 130	Extremadamente Alto

2.3 Ejemplo de Aplicación Práctica con Monóxido de Carbono (CO)

Para ilustrar el flujo de clasificación operativa en una hora determinada (por ejemplo, a las 14:00 hrs):

- **Lecturas retrospectivas (últimas 8 horas):**

- $[0.65, 0.72, 0.58, 0.81, 0.95, 1.10, 0.90, 0.85]\ ppm$
- **Evaluación de suficiencia:** Se cuenta con 8 de 8 registros válidos (100%), por lo que la ventana es estadísticamente válida.
- **Cálculo del promedio móvil:**

- $CO_{8h} = \frac{0.65+0.72+0.58+0.81+0.95+1.10+0.90+0.85}{8} = \frac{6.56}{8} = 0.82\ ppm$
- **Asignación categórica:**
  Al contrastar el valor de $0.82\ ppm$ contra los umbrales normativos implica que el registro es Bueno
- **Determinación del Índice Global Horario:**
  Si en esa misma hora los resultados concurrentes fueran $CO_{8h} = Buena$, $O_3 = Aceptable$, $PM_{10} = Aceptable$ y $PM_{2.5} = Mala$, el algoritmo selecciona la condición más restrictiva, reportando la categoría global horaria de la estación Miravalle como **Mala**.

3. Simulación y Procesamiento de la Información Horaria

El procesamiento horario constituye el núcleo analítico de alta resolución temporal del estudio, formulado para transformar registros instrumentales brutos en estimadores continuos de exposición inmediata según los lineamientos metodológicos de la **NOM-172-SEMARNAT-2023**.

3.1 Construcción del Archivo 1 y Dinámica Temporal

A partir de la serie continua de 744 horas de marzo de 2024 en la estación Miravalle, se ejecutó un pipeline vectorizado en Python para computar en paralelo los indicadores correspondientes a cada familia de contaminantes:

- **Ponderación Adaptativa con NowCast (PM_{10} y $PM_{2.5}$):** Se evaluaron ventanas móviles retrospectivas de 12 horas (t_{-11} a t_0). Cuando la atmósfera local presentó estabilidad, el factor de amortiguamiento se situó cercano a $W = 1.0$, promediando de forma cuasi-uniforme las concentraciones del

periodo. Ante fluctuaciones abruptas o incrementos rápidos de masa suspendida, el algoritmo ajustó automáticamente el peso hacia su cota inferior normativa ($W = 0.5$). Esto concentró la mitad del peso matemático en las horas más inmediatas, permitiendo que el reporte horario reaccionara con prontitud ante contingencias sin esperar la latencia de un promedio de 24 horas.

- **Atenuación Temporal del CO_{8h}:** El promedio móvil de 8 horas actuó como un filtro pasabajas de suavizado, eliminando picos transitorios generados por ráfagas de emisiones vehiculares sobre las avenidas colindantes y capturando la concentración de fondo acumulada a la que estuvo expuesta la población.
- **Inmediatez Fotoquímica del O_3:** Al emplear una resolución directa de 1 hora, se modeló con fidelidad el ciclo diurno de fotólisis, reflejando concentraciones basales bajas durante la madrugada y picos vespertinos atribuibles a la intensa radiación solar de la temporada seca.

3.2 Matriz de Jerarquización Horaria

Para cada una de las 744 horas del mes, se aplicó la regla del **contaminante más desfavorable** (principio de precaución en salud pública).

Bajo la escala ordinal ascendente de riesgo: $Buena < Aceptable < Mala < MuyMala < ExtremadamenteMala$.

4. Numeralia y Agregación Diaria (Periodo Marzo 2024)

El análisis diario consolida la representatividad ambiental del periodo evaluado en la estación Miravalle a través de la aplicación estricta de las reglas de agregación temporal, criterios de suficiencia muestral y jerarquización de riesgo de la **NOM-172-SEMARNAT-2023**.

4.1 Criterio de Suficiencia de Información (75%)

De conformidad con los protocolos federales, la representatividad estadística exige un umbral mínimo de **18 horas válidas de 24 posibles** (75% de completitud intradiaria). Los días con 17 o menos horas válidas recibieron la bandera "No cumple", bloqueando el cómputo de su indicador diario para prevenir distorsiones por submuestreo:

- **Monóxido de Carbono (CO): 29 días con suficiencia** (93.5%) | 2 días No cumple.
- **Ozono (O_3): 28 días con suficiencia** (90.3%) | 3 días No cumple.

- **Material Particulado PM_{10}: 27 días con suficiencia** (87.1%) | 4 días No cumple.
- **Material Particulado $PM_{2.5}$: 22 días con suficiencia** (71.0%) | 9 días No cumple (variable con mayor afectación por pérdida de telemetría o mantenimiento instrumental).

4.2 Estadísticos Descriptivos de los Indicadores Diarios

En los días que alcanzaron estatus de cumplimiento, se calcularon los estimadores normados, obteniendo las siguientes distribuciones cuantitativas:

- **PM10 (Promedio de 24 horas):**

  Concentración media mensual de 67.11 µg/m³ (desviación estándar: 13.01), con valores entre un mínimo de 41.00 µg/m³ y un máximo crítico de 90.00 µg/m³. La mediana fue de 64.00 µg/m³ sobre 27 días evaluados.

- **PM2.5 (Promedio de 24 horas):**

  Concentración media mensual de 24.14 µg/m³ (desviación estándar: 6.15), con un rango entre 13.00 µg/m³ y 35.00 µg/m³. La mediana fue de 25.00 µg/m³ sobre 22 días evaluados.

- **CO (Máximo del promedio móvil de 8 horas):**

  Media mensual de picos diarios de 0.88 ppm (desviación estándar: 0.17), con un valor mínimo de 0.51 ppm y un pico mensual absoluto de 1.22 ppm. La mediana fue de 0.90 ppm sobre 29 días válidos.

- **O3 (Máximo horario del día):**

  Media mensual de máximos horarios de 0.063 ppm (desviación estándar: 0.012), con valores entre un mínimo de 0.041 ppm y un máximo mensual de 0.091 ppm (equivalente a 91 ppb). La mediana fue de 0.060 ppm sobre 28 días válidos.

4.3 Distribución de Categorías Individuales por Contaminante

El cruce paramétrico de los indicadores con la tabla de intervalos normativos arrojó las siguientes frecuencias acumuladas:

- CO**: 29 días en condición Buena** y 2 días Sin datos. Confirmó la total ausencia de riesgo toxicológico por monóxido de carbono durante todo el mes.
- $PM_{2.5}$**: 19 días en Aceptable**, 2 días en **Buena**, **1 día en Mala** y 9 días Sin datos.
- O_3**: 14 días en Aceptable**, 13 días en **Buena**, **1 día en Mala** y 3 días Sin datos.
- PM_{10}**: 18 días en condición Mala**, 8 días en **Aceptable**, 1 día en **Buena** y 4 días Sin datos.

4.4 Categoría Global Diaria de la Estación Miravalle

Bajo el principio normativo del contaminante crítico (la peor condición define el estado general de la estación), el balance global de los 31 días de marzo de 2024 se estructuró de la siguiente forma:

- **Mala (Riesgo Alto): 18 días** (58.1% del mes).
- **Aceptable (Riesgo Moderado): 10 días** (32.3% del mes).
- **Buena (Riesgo Bajo): 1 día** (3.2% del mes).
- **Sin datos (Insuficiencia muestral general): 2 días** (6.5% del mes).

Determinación de Causalidad Ambiental:

El material particulado PM_{10} fue el vector absoluto de deterioro de la calidad del aire en la estación:

- De los 29 días válidos analizados, PM_{10} **fue el contaminante responsable de la condición diaria en 25 jornadas** (86.2%), mientras que el O_3 únicamente dictó la condición en **4 jornadas** (13.8%).
- Para los 18 días con estatus global **Mala**, el **100% (18 de 18 jornadas) fue originado exclusivamente por** PM_{10}, superando los umbrales de seguridad en la cuenca sur de la zona metropolitana.

4.5 Jornadas Críticas Más Desfavorables

Las jornadas con mayor concentración de partículas gruesas y proximidad a los límites superiores de la categoría Mala correspondieron a:

2024-03-05: Categoría Mala — PM10 = 90.00 µg/m³ (pico mensual del periodo).
2024-03-16: Categoría Mala — PM10 = 87.00 µg/m³.

2024-03-09: Categoría Mala — PM10 = 82.00 µg/m³.

2024-03-11: Categoría Mala — PM10 = 81.00 µg/m³.

2024-03-08: Categoría Mala — PM10 = 79.00 µg/m³.

4.6 Contraste Analítico: Perspectiva Horaria frente a Evaluación Diaria

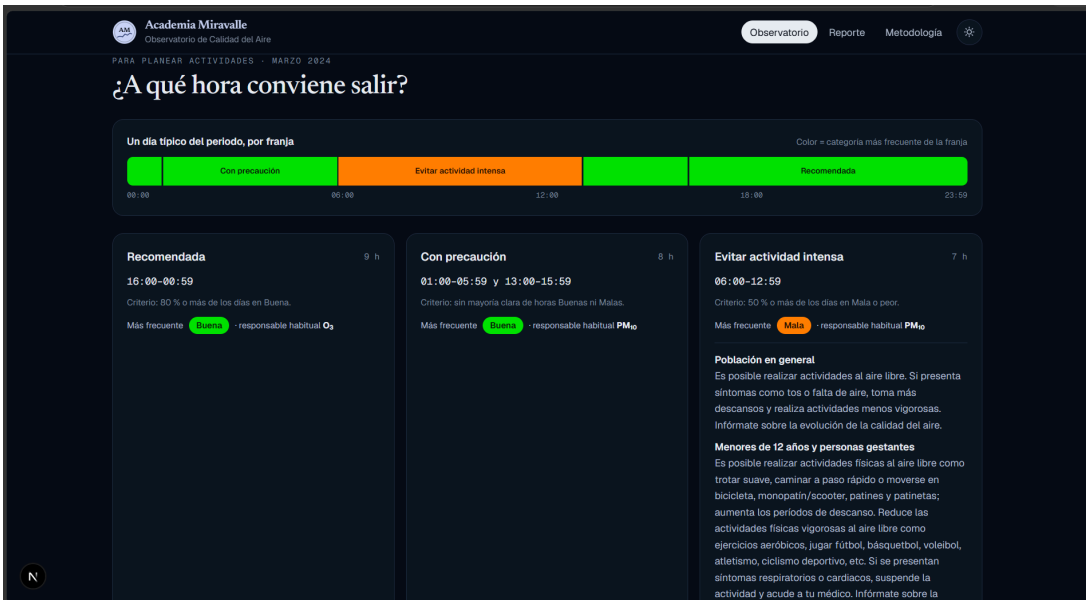
La contrastación entre las 744 horas del mes (Archivo 1) y los 31 cortes diarios (Archivo 2) evidenció divergencias representativas sobre la exposición humana:

- **Distribución Horaria Acumulada (708 horas válidas):**
  - **Buena:** 407 horas (57.5%).
  - **Aceptable:** 126 horas (17.8%).
  - **Mala:** 158 horas (22.3%).
  - **Muy Mala:** 17 horas (2.4%).
  - *Sin datos:* 36 horas.
- **Responsabilidad Horaria:** PM_{10} dominó en 402 horas (56.8%), seguido de O_3 con 197 horas (27.8%), $PM_{2.5}$ con 99 horas (14.0%) y CO con 10 horas (1.4%). Se registraron 154 transiciones o cambios de categoría intradiaria.
- **Fenómeno de Dilución Temporal y Exposición Aguda:**
  Mientras que a nivel horario el **57.5% de las horas presentaron calidad "Buena"**, a nivel diario únicamente el **3.4% de los días (1 jornada)** consolidó esta categoría. Esta asimetría demuestra que, a pesar de que durante las tardes y noches la dispersión atmosférica mejoraba los registros, los severos picos matutinos de PM_{10} asociados a la inversión térmica elevaron los promedios de 24 horas hacia rangos de riesgo crónico. Asimismo, se identificaron **59 horas con una categoría individual más severa que la categoría global de su respectivo día**, lo que subraya la pertinencia del reporte NowCast horario para la emisión de alertas tempranas en tiempo real frente a los cortes diarios agregados.

5. Visualización y Justificación de su Elección

Se optó por utilizar un Dashboard Web como herramienta principal de visualización, diseñado para representar los datos de calidad del aire mediante el codigo de color establecido por la NOM-172-SEMARNAT-2023. Este enfoque permite comunicar de manera clara y accesible la categoría vigente del aire cada día, utilizando los colores oficiales.

La elección de un Dashboard responde a la necesidad de integrar análisis técnico y comunicación pública. Desde la perspectiva académica, el dashboard facilita la exploración de patrones temporales y del espacio analizado, mientras que desde la perspectiva social cumple con la función de informar a la comunidad vecinal sobre los niveles de exposición y riesgo de la calidad del aire.



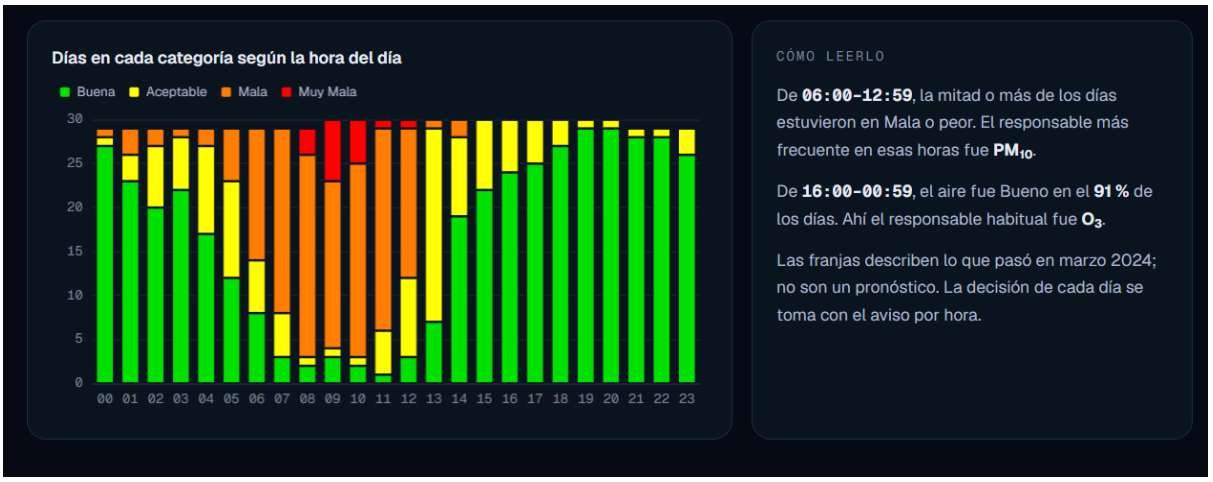


6. Principales Hallazgos

El análisis de marzo de 2024 en la estación Miravalle muestra una predominancia de la categoría Mala, con PM_{10} como el contaminante más determinante en la clasificación global.

Las mañanas concentraron los valores más altos de partículas, especialmente entre las 07:00 y las 12:00 horas, mientras que las tardes presentaron incrementos de ozono asociados a la radiación solar y a la dispersión atmosférica.

La categoría Buena no se presentó con frecuencia en el análisis y evaluación diario, Lo que evidencia una exposición constante a niveles de contaminación que pueden afectar la salud de la población sensible.



7. Interpretación desde la Perspectiva de la Agencia

Desde la perspectiva de la Academia, Miravalle recopila resultados que reflejan la necesidad de fortalecer la comunicación ambiental y la gestión de actividades al aire libre.

La comunidad en general realiza gran parte de sus actividades en exteriores, por lo que la exposición a partículas y ozono durante las mañanas hasta mediodía representa un riesgo moderado-alto.

Se recomienda ajustar los horarios de actividad física al aire libre, en medida de lo posible, recorrer estas actividades a un horario posterior a las 14:00 horas, cuando las condiciones del aire tienden a mejorar.

8. Conclusión y limitaciones

El estudio concluye que marzo de 2024 presentó una calidad del aire predominantemente mala en la estación Miravalle, con PM_{10} como principal contaminante y O3 como secundario durante horarios vespertinos. Una lectura diaria suaviza los picos de contaminantes que destacan en los horarios, por lo que utilizar un gráfico que represente los índices de manera horaria es la principal herramienta que se introduce, pues demuestra el alto impacto a la que se expone la población.

Entre las limitaciones del análisis se encuentran la cobertura temporal que cubre únicamente el mes de marzo, aunque este límite sirve perfectamente para exponer los resultados mensuales que son de utilidad para evaluar ese mes en especifico, tambien deja poco espacio para comparaciones igual de significantes, como mes con mes o una evaluación anual.
Igualmente la comparación con otras estaciones durante la misma temporada podría añadir un impacto significativamente mayor a los resultados.

Finalmente la ausencia de datos y atributos en algunos periodos podrían limitar análisis extensos y representativos de la situación actual en Miravalle.

9. Código o evidencia para Reproducir el Análisis

Limpieza de datos:

```python
#Limpieza de datos

import pandas as pd
from pathlib import Path

RAW_PATH = Path("BD_2024(1).xlsx")          # fuente original, solo lectura
OUTPUT_DIR = Path("processed")
OUTPUT_DIR.mkdir(exist_ok=True)

STATION_CODE = "MIR"  # Miravalle, según hoja Param

# ============================================================
# PASO 1. Carga y exploración inicial
# ============================================================
df_raw = pd.read_excel(RAW_PATH, sheet_name="Data")
param = pd.read_excel(RAW_PATH, sheet_name="Param")

print("--- PASO 1: Exploración inicial ---")
print(f"Filas totales en 'Data': {len(df_raw):,}")
print(f"Columnas (crudas, antes de limpiar nombres): {list(df_raw.columns)}")
print(f"Tipos de dato (dtypes):\n{df_raw.dtypes}")
print(f"Estaciones encontradas: {sorted(df_raw['STATION'].unique())}")
```

```
print(f"Valores nulos por columna:\n{df_raw.isnull().sum()}")

# ================================================================
# PASO 2. Filtrar solo Miravalle
# ================================================================
df_raw.columns = df_raw.columns.str.strip()  # "MES " trae un espacio de más en
el original
mir = df_raw[df_raw["STATION"] == STATION_CODE].copy()
print("\n--- PASO 2: Filtrado de Miravalle ---")
print(f"Filas de Miravalle: {len(mir):,}")
print(f"Rango de fechas: {mir['DATE'].min()} a {mir['DATE'].max()}")

# ================================================================
# PASO 3. Verificación de duplicados
#    Se revisa tanto el archivo completo (13 estaciones) como el
#    subconjunto de Miravalle, comparando por fila completa y por
#    llave estación+hora.
# ================================================================
print("\n--- PASO 3: Verificación de duplicados ---")
print(f"Filas 100% duplicadas (archivo completo): {df_raw.duplicated().sum()}")
print(f"Duplicados por STATION+DATE (archivo completo):
{df_raw.duplicated(subset=['STATION','DATE']).sum()}")
print(f"Filas 100% duplicadas (solo Miravalle): {mir.duplicated().sum()}")
print(f"Duplicados por DATE (solo Miravalle):
{mir.duplicated(subset=['DATE']).sum()}")

# ================================================================
# PASO 4. Revisión de tipos de dato y corrección de errores de formato
#    (PM2.5 se carga como texto por una celda con un valor no numérico)
# ================================================================
print("\n--- PASO 4: Tipos de dato y errores de formato ---")
valor_raro = mir.loc[mir["PM2.5"].apply(lambda x: isinstance(x, str)), ["DATE",
"PM2.5"]]
print(f"Valores de texto encontrados en PM2.5 (Miravalle): {len(valor_raro)}")
if len(valor_raro):
    print(valor_raro)

mir["PM2.5"] = pd.to_numeric(mir["PM2.5"], errors="coerce")
print("PM2.5 convertido a numérico. Nuevo dtype:", mir["PM2.5"].dtype)

# ================================================================
# PASO 5. Verificar integridad de la serie de tiempo
#    (sin huecos en la rejilla horaria)
# ================================================================
mir = mir.sort_values("DATE").reset_index(drop=True)
expected_hours = pd.date_range(mir["DATE"].min(), mir["DATE"].max(), freq="h")
missing_hours = expected_hours.difference(mir["DATE"])
```

```
print("\n--- PASO 5: Integridad de la serie de tiempo ---")
print(f"Horas faltantes en la rejilla (huecos en el índice, no en las
mediciones): {len(missing_hours)}")

# ================================================================
# PASO 6. Diagnóstico de valores faltantes por mes y por contaminante
#
# ================================================================
mir["mes"] = mir["DATE"].dt.month
contaminantes = ["O3", "NO2", "SO2", "CO", "PM10", "PM2.5"]
completeness = (
    mir.groupby("mes")[contaminantes]
    .apply(lambda g: g.notna().mean() * 100)
    .round(1)
)
completeness.to_csv(OUTPUT_DIR / "calidad_datos_miravalle_por_mes.csv")
print("\n--- PASO 6: % de datos disponibles por mes y contaminante ---")
print(completeness)

# ================================================================
# PASO 7. Detección de valores atípicos (método IQR)

# ================================================================
print("\n--- PASO 7: Valores atípicos (IQR), año completo Miravalle ---")
for c in ["O3", "CO", "PM10", "PM2.5"]:
    serie = mir[c].dropna()
    q1, q3 = serie.quantile(0.25), serie.quantile(0.75)
    iqr = q3 - q1
    lower, upper = q1 - 1.5 * iqr, q3 + 1.5 * iqr
    outliers = serie[(serie < lower) | (serie > upper)]
    print(
        f"{c}: límites=[{lower:.3f}, {upper:.3f}]  "
        f"atípicos={len(outliers)} ({len(outliers)/len(serie)*100:.1f}%)"
    )

# ================================================================
# PASO 8. Quedarse con las columnas relevantes para el proyecto

# ================================================================
columnas_nom172 = ["STATION", "DATE", "HOUR", "DIA", "MES", "O3", "NO2", "SO2",
"CO", "PM10", "PM2.5"]
mir_nom172 = mir[columnas_nom172].copy()

out_path = OUTPUT_DIR / "miravalle_2024_clean.csv"
mir_nom172.to_csv(out_path, index=False)
print(f"\n--- PASO 8: Archivo limpio exportado a: {out_path} ---")
```

```
# ================================================================
# PASO 9. Exportar el MISMO subconjunto limpio, acotado a un periodo

# ================================================================
def exportar_periodo(df_limpio, inicio, fin, nombre_archivo):
    periodo = df_limpio[(df_limpio["DATE"] >= inicio) & (df_limpio["DATE"] <=
fin)].copy()
    ruta = OUTPUT_DIR / nombre_archivo
    periodo.to_csv(ruta, index=False)
    print(f"Periodo {inicio} a {fin}: {len(periodo):,} filas -> {ruta}")
    return periodo


marzo_clean = exportar_periodo(
    mir_nom172, "2024-03-01", "2024-03-31 23:00:00",
"miravalle_marzo2024_clean.csv"
)
```

Generación de archivo Marzo 2024 Miravalle Horarios y Diarios

```
Python
import pandas as pd
import numpy as np
# Generación de archivos
#
================================================================================
# 1. FUNCIONES AUXILIARES
#
================================================================================

def NowCast_pandas(valores, PM):
    """
    Adaptación de la función NowCast para ser usada con pandas.rolling()
    """
    # pandas envía np.nan para datos faltantes; los convertimos a None
    valores_lista = [None if np.isnan(x) else x for x in valores]

    # Condición a): Al menos 2 de las 3 horas más recientes deben existir
    ultimas_3 = valores_lista[-3:] if len(valores_lista) >= 3 else
valores_lista
    if sum(x is not None for x in ultimas_3) < 2:
        return np.nan
```

```
    # Construir lista (valor, hora_consecutiva) respetando huecos (de reciente
a antiguo)
    valores_lista = valores_lista[::-1]
    datos = []
    for i, v in enumerate(valores_lista):
        if v is not None:
            datos.append((v, i))

    if len(datos) < 2:
        return np.nan

    solo_val = [v for v, _ in datos]
    rango = max(solo_val) - min(solo_val)
    w_raw = round(1 - (rango / max(solo_val)), 2) if max(solo_val) > 0 else 0.5
    W = w_raw if w_raw >= 0.5 else 0.5

    num = 0.0
    den = 0.0
    for v, hora_consec in datos:
        peso = (W ** hora_consec)
        num += v * peso
        den += peso

    if den == 0:
        return np.nan

    promedio = round(num / den, 0)

    # Ajuste de tu maestra (validar si se requiere para la entrega final)
    if PM == 0: # PM10
        promedio = round(promedio * 0.714, 0)
    else: # PM2.5
        promedio = round(promedio * 0.694, 0)

    return int(promedio)

def categorizar_contaminante(valor, contaminante):
    """
    Retorna la categoría del índice Aire y Salud según la NOM-172.
    NOTA: Ajusta los rangos o unidades (ppb a ppm) según tu necesidad exacta.
    """
    if pd.isna(valor):
        return 'Sin datos'

    # Puntos de corte oficiales NOM-172
    cortes = {
        'PM10':  [0, 45, 70, 132, 213, np.inf], # µg/m³
```

```
        'PM2.5': [0, 15, 41, 79, 130, np.inf],  # µg/m³
        'O3':    [0, 0.058, 0.090, 0.135, 0.175, np.inf], # ppm
        'CO':    [0, 5, 9, 12, 16, np.inf]      # ppm
    }

    categorias = ['Buena', 'Aceptable', 'Mala', 'Muy Mala', 'Extremadamente
Mala']


    if contaminante in cortes:
        # Encuentra la categoría usando los límites
        for i, limite_superior in enumerate(cortes[contaminante][1:]):
            if valor <= limite_superior:
                return categorias[i]
    return 'Sin datos'

def obtener_categoria_global(fila, columnas_categorias):
    niveles = {'Buena': 1, 'Aceptable': 2, 'Mala': 3, 'Muy Mala': 4,
'Extremadamente Mala': 5, 'Sin datos': 0}
    inv_niveles = {v: k for k, v in niveles.items()}

    # Encuentra el nivel máximo (peor condición) de la fila actual
    max_nivel = max([niveles.get(fila[col], 0) for col in columnas_categorias])
    return inv_niveles[max_nivel]

#
================================================================================
# 2. PROCESAMIENTO PRINCIPAL
#
================================================================================

# 1. Cargar datos
df = pd.read_csv('miravalle_marzo2024_cleanFinal.csv')
df['DATE'] = pd.to_datetime(df['DATE'])
df = df.sort_values(by='DATE').reset_index(drop=True) # Asegurar orden
cronológico

# ----- ARCHIVO 1: CÁLCULOS HORARIOS -----

# Calcular NowCast para PM10 y PM2.5 (Ventana de 12h)
df['NowCast_PM10'] = df['PM10'].rolling(window=12, min_periods=1).apply(lambda
x: NowCast_pandas(x, 0), raw=True)
df['NowCast_PM25'] = df['PM2.5'].rolling(window=12, min_periods=1).apply(lambda
x: NowCast_pandas(x, 1), raw=True)

# Calcular Promedio Móvil de 8h para CO (requiere al menos 6 datos = 75%)
df['CO_8h'] = df['CO'].rolling(window=8, min_periods=6).mean()
```

```
#ajuste que
agregué-----------------------------------------------------------------
#df['CO_8h'] = df['CO_8h'].round(2)
# Asignar categorías horarias (Omitimos NO2 y SO2 por estar vacíos)
df['Cat_O3'] = df['O3'].apply(lambda x: categorizar_contaminante(x, 'O3'))
df['Cat_CO'] = df['CO_8h'].apply(lambda x: categorizar_contaminante(x, 'CO'))
df['Cat_PM10'] = df['NowCast_PM10'].apply(lambda x: categorizar_contaminante(x,
'PM10'))
df['Cat_PM25'] = df['NowCast_PM25'].apply(lambda x: categorizar_contaminante(x,
'PM2.5'))

# Categoría Global Horaria
cols_cat = ['Cat_O3', 'Cat_CO', 'Cat_PM10', 'Cat_PM25']
df['Cat_Global_Horaria'] = df.apply(lambda fila: obtener_categoria_global(fila,
cols_cat), axis=1)

# Guardar Archivo 1
columnas_archivo1 = ['STATION', 'DATE', 'HOUR', 'O3', 'CO', 'PM10', 'PM2.5',
                     'NowCast_PM10', 'NowCast_PM25', 'CO_8h'] + cols_cat +
['Cat_Global_Horaria']
df_horario = df[columnas_archivo1]
df_horario.to_csv('Archivo1_Calculos_Horarios.csv', index=False)
print("Archivo 1 generado con éxito.")

# ----- ARCHIVO 2: CÁLCULOS DIARIOS -----

# Extraer solo el día para agrupar
df['DIA_FECHA'] = df['DATE'].dt.date

datos_diarios = []
grupos = df.groupby('DIA_FECHA')

for dia, grupo in grupos:
    fila_dia = {'Fecha': dia}

    for cont, col_origen, col_indicador, tipo_calculo in [
        ('PM10', 'PM10', 'PM10', 'promedio_24h'),
        ('PM2.5', 'PM2.5', 'PM2.5', 'promedio_24h'),
        ('CO', 'CO', 'CO_8h', 'maximo'),
        ('O3', 'O3', 'O3', 'maximo')
    ]:
        # 1. Contar datos válidos de la lectura original del instrumento (18
horas)
        validos = grupo[col_origen].count()
        cumple = 'Cumple' if validos >= 18 else 'No cumple'

        # 2. Calcular indicador diario si cumple
```

```
        indicador = np.nan
        if cumple == 'Cumple':
            if tipo_calculo == 'promedio_24h':
                indicador = round(grupo[col_origen].mean(), 2)
            elif tipo_calculo == 'maximo':
                indicador = round(grupo[col_indicador].max(), 2)

        # 3. Categoría diaria
        categoria = categorizar_contaminante(indicador, cont)

        # Llenar fila
        fila_dia[f'Validos_{cont}'] = validos
        fila_dia[f'Suficiencia_{cont}'] = cumple
        fila_dia[f'Indicador_{cont}'] = indicador
        fila_dia[f'Cat_{cont}'] = categoria

    datos_diarios.append(fila_dia)

df_diario = pd.DataFrame(datos_diarios)

# Categoría Global Diaria
cols_cat_diarias = ['Cat_PM10', 'Cat_PM2.5', 'Cat_CO', 'Cat_O3']
df_diario['Cat_Global_Diaria'] = df_diario.apply(lambda fila:
obtener_categoria_global(fila, cols_cat_diarias), axis=1)

# Guardar Archivo 2
df_diario.to_csv('Archivo2_Calculos_Diarios.csv', index=False)
print("Archivo 2 generado con éxito.")
```

Resultados finales para dashboard:

Python

```
import pandas as pd
# Resultados
# 1. Cargar datos desde el archivo CSV diario
df = pd.read_csv('Archivo2_Calculos_Diarios.csv')

contaminantes = ['PM10', 'PM2.5', 'CO', 'O3']
total_dias = len(df)

print("=" * 65)
print(f"ANÁLISIS DE RESULTADOS DIARIOS - ESTACIÓN MIRAVALLE ({total_dias}
DÍAS)")
print("=" * 65)
```

```python
# 2. Análisis del Criterio de Suficiencia (75% / >= 18 horas válidas)
print("\n" + "-" * 40)
print("1. EVALUACIÓN DE SUFICIENCIA DIARIA")
print("-" * 40)

for cont in contaminantes:
    col_suf = f'Suficiencia_{cont}'
    conteo_suf = df[col_suf].value_counts()
    cumple = conteo_suf.get('Cumple', 0)
    no_cumple = conteo_suf.get('No cumple', 0)
    pct_cumple = (cumple / total_dias) * 100
    print(f"{cont:6}: {cumple} días Cumple ({pct_cumple:.1f}%) | {no_cumple}
días No cumple")

# 3. Estadísticos Descriptivos de los Indicadores Diarios
print("\n" + "-" * 40)
print("2. ESTADÍSTICAS DE LOS INDICADORES CALCULADOS")
print("-" * 40)

for cont in contaminantes:
    col_ind = f'Indicador_{cont}'
    stats = df[col_ind].describe()
    unidad = "ppm" if cont in ['CO', 'O3'] else "µg/m³"
    print(f"\nIndicador Diario {cont} ({unidad}):")
    print(f"  - Días evaluados: {int(stats['count'])}")
    print(f"  - Media mensual:  {stats['mean']:.2f}")
    print(f"  - Desv. estándar: {stats['std']:.2f}")
    print(f"  - Mínimo:         {stats['min']:.2f}")
    print(f"  - Mediana (Q2):   {stats['50%']:.2f}")
    print(f"  - Máximo:         {stats['max']:.2f}")

# 4. Distribución de Categorías Individuales
print("\n" + "-" * 40)
print("3. CATEGORÍAS INDIVIDUALES POR CONTAMINANTE")
print("-" * 40)

for cont in contaminantes:
    col_cat = f'Cat_{cont}'
    print(f"\nDistribución para {cont}:")
    conteo_cat = df[col_cat].value_counts()
    for cat, freq in conteo_cat.items():
        print(f"  - {cat:15}: {freq} días")

# 5. Distribución de la Categoría Global Diaria de la Estación
print("\n" + "-" * 40)
print("4. CATEGORÍA GLOBAL DIARIA DE LA ESTACIÓN (PEOR CONDICIÓN)")
```

```
print("-" * 40)

conteo_global = df['Cat_Global_Diaria'].value_counts()
for cat, freq in conteo_global.items():
    pct = (freq / total_dias) * 100
    print(f"  - {cat:15}: {freq} días ({pct:.1f}%)")

# 6. Identificación de contaminantes críticos en días "Mala"
print("\n" + "-" * 40)
print("5. CONTAMINANTES RESPONSABLES DE DÍAS CON CONDICIÓN 'MALA'")
print("-" * 40)

dias_malos = df[df['Cat_Global_Diaria'] == 'Mala']
print(f"Total de días en condición Mala: {len(dias_malos)}")

pm10_responsable = (dias_malos['Cat_PM10'] == 'Mala').sum()
o3_responsable = (dias_malos['Cat_O3'] == 'Mala').sum()
co_responsable = (dias_malos['Cat_CO'] == 'Mala').sum()
pm25_responsable = (dias_malos['Cat_PM2.5'] == 'Mala').sum()

print(f"  - Días donde PM10 estuvo en Mala:  {pm10_responsable}")
print(f"  - Días donde O3 estuvo en Mala:    {o3_responsable}")
print(f"  - Días donde PM2.5 estuvo en Mala: {pm25_responsable}")
print(f"  - Días donde CO estuvo en Mala:    {co_responsable}")
```

Reporte del líder Sprint 1

La siguiente bitácora resume la participación de los seis integrantes en la preparación, transformación, análisis y presentación de los datos de marzo de 2024 de la estación Miravalle.

Integrante	Actividades realizadas	Cumplimiento	Observaciones
Jesús Ernesto Vallejo Ayala	Coordinación del equipo, integración del reporte, revisión de los cálculos de la NOM y preparación de la entrega final.	Completo	Organizó los productos y verificó la coherencia entre los resultados horarios y diarios.
José Alberto Bautista Bautista	Preparación de la base, revisión de tipos de datos, unidades, valores faltantes y continuidad temporal.	Completo	Documentó los problemas de calidad y los criterios utilizados para la limpieza.
Juan Manuel Ramos Reynaga	Revisión del cálculo de NowCast y desarrollo de la simulación de la llegada progresiva de datos horarios.	Completo	Identificó los cambios de categoría y los momentos principales del evento seleccionado.
Adrián Ruiz Garfias	Cálculo de indicadores diarios, verificación de suficiencia y determinación de categorías por contaminante.	Completo	Comprobó que los indicadores no se calcularan cuando la cobertura era insuficiente.
María Alondra Castillo Galindo	Elaboración de la numeralia, calendario diario y revisión de las visualizaciones del reporte.	Completo	Sintetizó las categorías diarias y los contaminantes dominantes de forma clara.
Braulio Jiménez Chavez	Interpretación meteorológica, redacción de hallazgos, conclusiones, limitaciones y revisión de referencias.	Completo	Mantuvo la interpretación descriptiva y evitó presentar asociaciones como relaciones causales.

El equipo cumplió con las actividades necesarias para preparar, transformar, visualizar e interpretar la información de marzo de 2024. La distribución del trabajo permitió revisar tanto la calidad de los datos como la aplicación de la NOM-172-SEMARNAT-2023, y facilitó la comparación entre las escalas horaria y diaria. La participación de los integrantes permitió integrar un producto coherente y con evidencia técnica reproducible.

Para el siguiente sprint se deberá registrar la participación conforme avance el trabajo, mejorar el uso del control de versiones, documentar con mayor detalle las decisiones técnicas e incorporar pruebas automáticas para los casos de suficiencia, redondeo y datos faltantes. También será conveniente validar la disponibilidad de los sensores antes de seleccionar las variables que formarán parte del análisis.

Declaración de IA generativa y tecnologías asistidas por IA

Durante la preparación de este trabajo, el autor o los autores utilizaron **Gemini (Google)** para **la asistencia en la estructuración y depuración de scripts en Python (adaptación del algoritmo NowCast, promedios móviles y criterios de suficiencia de la NOM-172-SEMARNAT-2023), la resolución de inconsistencias en formatos de exportación de datos y el apoyo en la redacción técnica y síntesis del reporte analítico**. Después de utilizar esta herramienta/servicio, el autor o los autores revisaron y editaron el contenido según fuera necesario y asumen la total responsabilidad por el contenido de este trabajo.